数据来源

MOVER（美国）

57,473 台 / 38,245 人

开发数据源
评价子集 4,000 台

本院专病库
（腹部肿瘤手术）

7,079 台 / 6,804 人

开发 2021–24：4,326 台
时间外验证 2025–26：2,753 台

VitalDB（韩国首尔）

6,242 台 / 5,961 人

第二站点
训练 4,357 台 / 测试 1,885 台

输入

T1

共有结构化变量
年龄、性别、BMI、病史、
血压心率、化验、手术名

T2

T1 + 术前文本
本院：麻醉前访视原文
VitalDB：诊断与检查

比较的做法（同一底模 Qwen3.5-9B）

生成式零样本提示

先写不超过 3 句的理由再作答
逐词解码，平均约 89 个输出词元

开源非生成式决策模型（一次前向计算，不生成文本）

最小决策模型

选项字母 A–D 的 logits → softmax



OpenJev

Jev 的开源兼容实现
冻结配置，全部在院内运行

校准决策模型：在期望分 $E = \Sigma_j j\, p_j$ 上，用 k 个本地标签拟合 3 个切点



任务 LoRA（4-bit QLoRA）

以 n 个本地标签训练（100 至全量，3 个种子）
每个站点训练并保存一个适配器

评价

H1 优效

最小决策模型
> 生成式零样本

H2 非劣效（界值 0.05）

校准决策模型（1,000 标签）
对 LoRA@1,000

H3 优效

全量 LoRA
> 校准决策模型

主要指标

相对站点记录的二次加权 κ
患者层面 cluster bootstrap

同时报告

延迟、词元、GPU 时间、
所需标签数、ECE、矛盾内容